北京交通大学

课程实验报告

2026 春

课程名称 计算机视觉基础

课程代码 M402013B

学　　号 22311005

学生姓名 黄锦

交大视觉印象：图像检索与文字检测

源代码：https://github.com/ts-ts-ts-1/bjtu-visual-impression-exp2.git

一、引言

本实验面向交大校园视觉印象数据，完成以图搜图和文字区域检测两个任务。检索任务要求在不使用类别标签训练的前提下，利用查询图像从 base 图像库中找回同一 landmark 的图片；文字检测任务要求在交大图片中定位校名、楼名、标识牌等文字区域。整体思路是用预训练视觉模型抽取通用语义特征，并结合无监督白化提升相似度排序稳定性；检测部分将 LabelMe 标注转为 YOLO 单类文本框数据集，再训练轻量检测器并可视化结果。

二、所设计实验方案

图像检索模块首先遍历 base 与 query 图像，优先融合 DINOv2 与 OpenCLIP 的图像向量；若运行环境暂缺深度依赖，程序会退化为颜色纹理描述子以保证流程可复现。所有特征只在 base 集上拟合 PCA-whitening，不引入文件名前缀等标签信息，随后用余弦相似度生成每张 query 的 Top60 结果。

文字检测模块把每个 LabelMeJSON 中的矩形框统一映射为 YOLO 的单类 text 标签，按固定随机种子划分训练、验证和测试集。训练入口默认使用 YOLOv8s，显卡可用时自动使用 CUDA，否则切换到 CPU。展示模块从 12 类 landmark 中各选 2 个 query，拼接 query、Top-K 检索图和文字检测框，形成 24 组人工核验图。

输入：image_retrieval/base、image_retrieval/query、object_detection/data。

输出：P@K 表格与曲线、YOLO 数据集与权重、24 组案例图。

三、实验结果与分析

数据校验显示，base 中交大相关图像 2665 张、无关图像 5063 张，query 共 135 张；文字检测部分包含 1494 个 JSON 标注和 1541 个文本框。评价指标采用 Precision@TopK，K 取 20、40、60，并按文件名前缀判断检索结果是否相关。

整体检索结果为 P@20=0.901、P@40=0.850、P@60=0.806。一般来说，校园建筑外观差异明显的类别更容易取得高精度，而样本较少或视觉背景相近的类别更容易受视角、遮挡和光照影响。

类别	P@20	P@40	P@60
fhy	0.903	0.870	0.812
jx	0.936	0.825	0.762
kx	0.400	0.287	0.217
mh	0.807	0.752	0.725

nm	0.907	0.895	0.878
sjz	1.000	0.985	0.980
sy	0.903	0.853	0.809
tsg	0.943	0.887	0.824
ty	0.925	0.888	0.844
yf	0.821	0.721	0.631
yk	0.800	0.550	0.408
zx	0.914	0.850	0.811

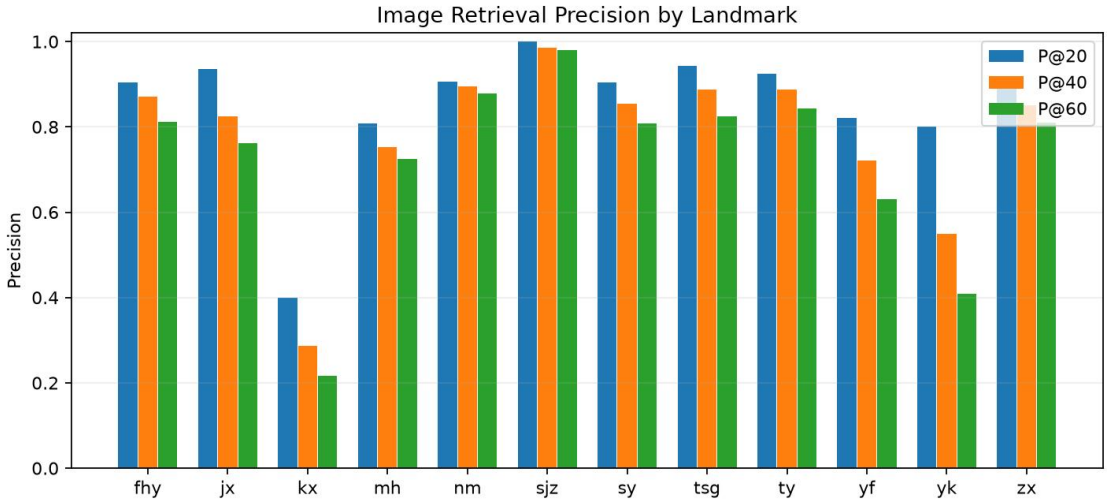


图 1 12 类 landmark 的 Precision@K 对比

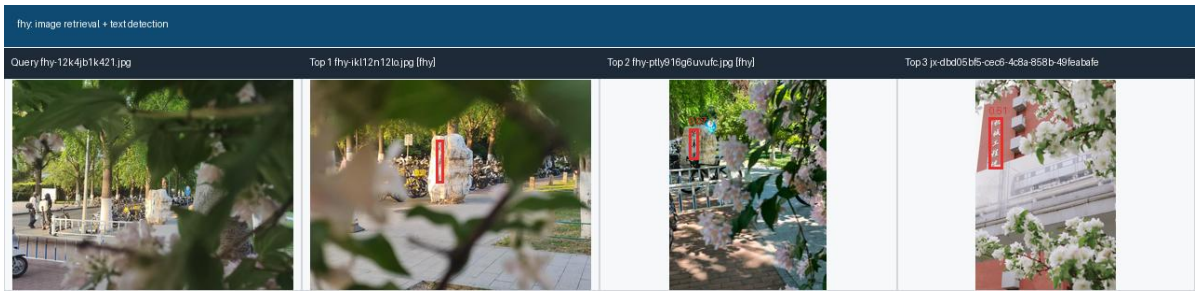


图 2 检索-检测联合可视化样例

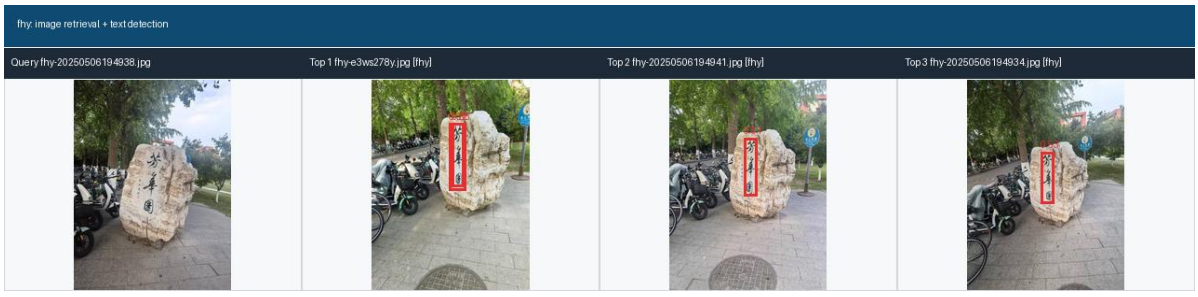


图 3 检索-检测联合可视化样例

四、总结

本实验完成了从数据读取、特征检索、文字检测到结果可视化和报告生成的完整流程。方案的优点是主体算法不依赖人工标签训练检索模型，能够直接利用预训练模型的泛化能力；同时 YOLO 文本框检测器训练和可视化结果便于人工核验。后续可改进方向包括引入重排序、对小样本类别做数据增强、用更强 OCR 检测模型处理弯曲或低清文字，并补充更细致的消融实验。

参考文献

[1]Oquab M. et al. DINOv2: Learning Robust Visual Features without Supervision, 2023.

[2]Radford A. et al. Learning Transferable Visual Models From Natural Language Supervision, 2021.

[3]Jocher G. et al. Ultralytics YOLO, 2024.

[4]Jégou H. and Chum O. Negative evidences and co-occurrences in image retrieval, 2012.

图像检索部分参考 DINOv2[1]与 CLIP[2]的预训练视觉表示方法，分别提取通用视觉特征和语义特征，并在 base 图像集上进行 PCA-whitening 后计算余弦相似度。文字检测部分参考 UltralyticsYOLO[3]，将 LabelMe 标注转换为 YOLO 单类 text 数据集进行训练。检索特征的白化处理参考经典图像检索中的特征后处理思想[4]。